

Análise de RNA-seq: knockdown de MEIS1 versus WT

Este repositório/documento descreve um fluxo de análise de dados de RNA-seq de células-tronco humanas, comparando amostras com **knockdown de MEIS1 (MEIS1 KD)** e células **wild type (WT)**. O pipeline inclui download e subamostragem dos dados, controle de qualidade, alinhamento ao genoma GRCh38, quantificação gênica, expressão diferencial e análise de enriquecimento funcional por GSEA.

Observação: os dados utilizados são subamostras dos arquivos originais, reduzidas para permitir a execução em um computador com 8 GB de RAM. Portanto, os resultados servem principalmente para fins exploratórios e didáticos.

Dataset

O conjunto de dados foi selecionado no GEO Datasets usando uma busca por:

(Homo sapiens[Organism]) AND Expression profiling by high throughput sequencing AND s

Foi utilizado o estudo:

- **GEO:** [GSE322827](#)
- **SRA study:** [SRP680865](#)
- **Organismo:** *Homo sapiens*
- **Tipo de dado:** RNA-seq de leitura pareada (*paired-end*)
- **Número de amostras analisadas:** 6
- **Condições:** 3 MEIS1 KD e 3 WT

Amostras

Amostra	Condição
SRR37459106	MEIS1 KD
SRR37459107	MEIS1 KD
SRR37459108	MEIS1 KD
SRR37459109	WT
SRR37459110	WT
SRR37459111	WT

Estrutura esperada

```
.
├── subamostras/
│   ├── SRR37459106_1.fastq.gz
│   ├── SRR37459106_2.fastq.gz
│   └── ...
├── subamostras_5M/
│   ├── SRR37459106_1.fastq.gz
│   ├── SRR37459106_2.fastq.gz
│   └── ...
├── qc_raw/
├── hisat2_grch38/
│   └── grch38/
├── aligned/
│   ├── *.sorted.bam
│   ├── *.sorted.bam.bai
│   └── *.flagstat.txt
├── referencia/
│   └── Homo_sapiens.GRCh38.84.gtf
├── counts/
│   └── all_samples_counts.txt
├── expressao_diferencial_gsea/
└── align.sh
```

Requisitos

O fluxo depende das seguintes ferramentas e bibliotecas:

- Conda ou Mamba
- SRA Toolkit
- FastQC
- MultiQC
- HISAT2
- SAMtools
- Seqtk
- Subread/featureCounts
- Python 3
- NumPy
- Pandas
- Matplotlib
- Seaborn
- PyDESeq2
- GSEAPy
- MyGene

O índice de referência utilizado no alinhamento foi o índice do GRCh38 disponibilizado pelo HISAT2:

- [Índice GRCh38 do HISAT2](#)
- [Página de downloads do HISAT2](#)

1. Download dos dados

Crie um ambiente para as ferramentas do SRA Toolkit:

```
conda create -n sra -c conda-forge -c bioconda "sra-tools>=3.1"
conda activate sra

prefetch --version
```

O estudo pode ser baixado utilizando o identificador do projeto SRA:

```
prefetch SRP680865
```

Para gerar arquivos FASTQ pareados e limitar inicialmente o número de reads:

```
mkdir -p subamostras

fastq-dump SRR37459106 --split-files -O subamostras -X 5000000
fastq-dump SRR37459107 --split-files -O subamostras -X 5000000
fastq-dump SRR37459108 --split-files -O subamostras -X 5000000
fastq-dump SRR37459109 --split-files -O subamostras -X 5000000
fastq-dump SRR37459110 --split-files -O subamostras -X 5000000
fastq-dump SRR37459111 --split-files -O subamostras -X 5000000
```

Os arquivos _1 e _2 correspondem às duas extremidades das leituras paired-end.

Para análises completas, recomenda-se utilizar fasterq-dump ou uma estratégia equivalente com espaço em disco e recursos computacionais suficientes. Neste trabalho, a subamostragem foi necessária por limitações de memória.

2. Controle de qualidade

Crie um diretório para os relatórios do controle de qualidade:

```
mkdir -p qc_raw
```

Execute o FastQC em todos os arquivos FASTQ compactados:

```
fastqc -t 4 -o qc_raw ./subamostras/*.fastq.gz
```

Consolide os relatórios utilizando o MultiQC:

```
multiqc qc_raw -o qc_raw
```

Os principais pontos avaliados foram:

1. Qualidade das bases ao longo das leituras.
2. Presença de adaptadores.
3. Nível de duplicação.
4. Conteúdo GC.
5. Diferenças entre as amostras.
6. Necessidade de trimming.

A amostra **SRR37459108** apresentou desempenho inferior em algumas métricas de qualidade, especialmente em relação à qualidade por posição, e posteriormente também apresentou a menor taxa de alinhamento.

3. Preparação do índice GRCh38

Baixe e descompacte o índice do HISAT2:

```
mkdir -p hisat2_grch38
cd hisat2_grch38

wget https://genome-id3.s3.amazonaws.com/hisat/grch38_genome.tar.gz
tar -xzf grch38_genome.tar.gz
cd ..
```

O índice contém arquivos semelhantes a:

```
hisat2_grch38/
├─ grch38/
│   ├── genome.1.ht2
│   ├── genome.2.ht2
│   ├── genome.3.ht2
│   ├── genome.4.ht2
│   ├── genome.5.ht2
│   ├── genome.6.ht2
│   ├── genome.7.ht2
│   ├── genome.8.ht2
│   └─ make_grch38.sh
```

4. Alinhamento com HISAT2

Inicialmente, foi utilizado um script com 8 threads para alinhar as leituras e ordenar os arquivos BAM:

```
mkdir -p aligned

hisat2 -p 8 -x ./hisat2_grch38/grch38/genome \
```

```
-1 subamostras/SRR37459106_1.fastq.gz \  
-2 subamostras/SRR37459106_2.fastq.gz \  
| samtools sort -@ 8 -o aligned/SRR37459106.sorted.bam
```

O mesmo procedimento foi aplicado às seis amostras. Em seguida, os arquivos BAM foram indexados e avaliados com flagstat:

```
samtools index aligned/SRR37459106.sorted.bam  
samtools flagstat aligned/SRR37459106.sorted.bam > aligned/SRR37459106.flagstat.txt
```

Problema de memória

A primeira tentativa falhou por falta de memória:

```
Killed  
(ERR): hisat2-align exited with value 137  
[E::sam_parse1] SEQ and QUAL are of different length  
samtools sort: truncated file. Aborting
```

O código de saída 137 é compatível com encerramento do processo pelo sistema por excesso de uso de memória. O erro de arquivo truncado foi uma consequência da interrupção do HISAT2, e não necessariamente um problema original na estrutura dos FASTQ.

Para reduzir o consumo de memória, foram criadas novas subamostras contendo aproximadamente 5 milhões de reads por amostra, ou 2,5 milhões de pares:

```
mkdir -p subamostras_5M  
  
seqtk sample -s 100 subamostras/SRR37459106_1.fastq.gz 2500000 | gzip > subamostras_5M/SRR37459106_1.fastq.gz  
seqtk sample -s 100 subamostras/SRR37459106_2.fastq.gz 2500000 | gzip > subamostras_5M/SRR37459106_2.fastq.gz  
  
seqtk sample -s 100 subamostras/SRR37459107_1.fastq.gz 2500000 | gzip > subamostras_5M/SRR37459107_1.fastq.gz  
seqtk sample -s 100 subamostras/SRR37459107_2.fastq.gz 2500000 | gzip > subamostras_5M/SRR37459107_2.fastq.gz  
  
seqtk sample -s 100 subamostras/SRR37459108_1.fastq.gz 2500000 | gzip > subamostras_5M/SRR37459108_1.fastq.gz  
seqtk sample -s 100 subamostras/SRR37459108_2.fastq.gz 2500000 | gzip > subamostras_5M/SRR37459108_2.fastq.gz  
  
seqtk sample -s 100 subamostras/SRR37459109_1.fastq.gz 2500000 | gzip > subamostras_5M/SRR37459109_1.fastq.gz  
seqtk sample -s 100 subamostras/SRR37459109_2.fastq.gz 2500000 | gzip > subamostras_5M/SRR37459109_2.fastq.gz  
  
seqtk sample -s 100 subamostras/SRR37459110_1.fastq.gz 2500000 | gzip > subamostras_5M/SRR37459110_1.fastq.gz  
seqtk sample -s 100 subamostras/SRR37459110_2.fastq.gz 2500000 | gzip > subamostras_5M/SRR37459110_2.fastq.gz  
  
seqtk sample -s 100 subamostras/SRR37459111_1.fastq.gz 2500000 | gzip > subamostras_5M/SRR37459111_1.fastq.gz  
seqtk sample -s 100 subamostras/SRR37459111_2.fastq.gz 2500000 | gzip > subamostras_5M/SRR37459111_2.fastq.gz
```

5. Resultados do alinhamento

Após a subamostragem, as taxas gerais de alinhamento foram:

Amostra	Taxa de alinhamento
SRR37459106	82,77%
SRR37459107	83,78%
SRR37459108	74,81%
SRR37459109	84,21%
SRR37459110	81,40%
SRR37459111	85,05%

A amostra **SRR37459108** apresentou a menor taxa de alinhamento, aproximadamente 74,81%, enquanto as demais ficaram entre 81,40% e 85,05%. Essa diferença é consistente com os resultados de controle de qualidade e sugere que essa amostra possui maior proporção de reads de baixa qualidade, contaminantes, sequências não representadas no índice ou outras características técnicas que dificultam o alinhamento.

A taxa de alinhamento, entretanto, não identifica sozinha a causa do problema. Para investigar melhor, seria necessário revisar os relatórios do FastQC/MultiQC, verificar adaptadores, conteúdo GC, qualidade por ciclo, duplicação e possíveis diferenças de preparação entre as bibliotecas.

6. Quantificação com featureCounts

Instale o Subread:

```
mamba install subread
```

Baixe o arquivo GTF utilizado para a anotação:

```
mkdir -p referencia

wget ftp://ftp.ensembl.org/pub/release-84/gtf/homo_sapiens/Homo_sapiens.GRCh38.84.gtf
gunzip referencia/Homo_sapiens.GRCh38.84.gtf.gz
```

A contagem foi realizada com:

```
mkdir -p counts

featureCounts -T 4 -p -s 2 \
  -a referencia/Homo_sapiens.GRCh38.84.gtf \
  -o counts/all_samples_counts.txt \
  aligned/*.sorted.bam
```

Parâmetros principais:

- `-T 4`: utiliza quatro threads.
- `-p`: considera leituras paired-end.
- `-s 2`: assume biblioteca com orientação reversa (*reverse-stranded*).
- `-a`: especifica o arquivo GTF.
- `-o`: define o arquivo de saída.

Resumo da contagem

Status	SRR37459106	SRR37459107	SRR37459108	SRR37459109	SRR37459110	SRR37459111
Assigned	3.635.388	3.615.660	3.293.791	3.703.521	3.559.279	3.769.454
Unassigned_Unmapped	861.476	810.810	1.259.647	789.314	930.156	747.419
Unassigned_MultiMapping	537.493	692.789	410.455	600.063	583.868	476.167
Unassigned_NoFeatures	210.392	248.498	195.972	205.374	220.738	205.453
Unassigned_Ambiguity	131.211	130.225	125.227	128.588	121.868	129.565

A amostra SRR37459108 teve o menor número de reads atribuídos a genes e o maior número de reads não mapeados, reforçando o diagnóstico de que ela apresenta qualidade ou composição diferente das demais.

7. Expressão diferencial

A matriz de contagens produzida pelo `featureCounts` foi analisada com `PyDESeq2`, uma implementação em Python da modelagem estatística utilizada pelo `DESeq2`. O procedimento incluiu:

- Normalização por fatores de tamanho.
- Estimativa da dispersão.
- Ajuste de um modelo linear generalizado binomial negativo.
- Teste de Wald.
- Comparação entre MEIS1 KD e WT.

As amostras foram organizadas da seguinte forma:

```
condition_map = {
    "SRR37459106": "MEIS1_KD",
    "SRR37459107": "MEIS1_KD",
    "SRR37459108": "MEIS1_KD",
    "SRR37459109": "WT",
    "SRR37459110": "WT",
    "SRR37459111": "WT",
}
```

Foi aplicado um filtro mínimo, mantendo genes cuja soma das contagens nas seis amostras fosse maior ou igual a 10. Dos 60.675 genes anotados no GTF, 15.631 permaneceram após o filtro.

O contraste utilizado foi:

```
MEIS1_KD versus WT
```

Foram considerados genes diferencialmente expressos aqueles com:

```
padj < 0,05 e |log2FoldChange| > 1
```

Arquivos gerados

```
expressao_diferencial_gsea/  
├─ deseq2_results_all_genes.csv  
├─ deseq2_results_sig_padj0.05_lfc1.csv  
├─ pca_coordinates.csv  
├─ pca.png  
├─ volcano.png  
├─ heatmap_top_degs.png  
├─ ranked_gene_list_for_gsea.csv  
├─ gsea_prerank_report.csv  
├─ gsea_dotplot.png  
└─ gsea_top3_running_score.png
```

8. PCA

A análise de componentes principais foi realizada sobre dados transformados por VST. O primeiro componente principal explicou 41,8% da variância e separou claramente as amostras MEIS1 KD das amostras WT.

A amostra SRR37459108 apareceu mais distante das outras duas réplicas MEIS1 KD. Esse comportamento é consistente com:

- Menor taxa de alinhamento.
- Maior proporção de reads não mapeados.
- Menor quantidade de reads atribuídos a genes.
- Pior desempenho em métricas do FastQC.

Assim, SRR37459108 deve ser considerada uma amostra potencialmente discrepante. No entanto, a remoção de uma réplica deve ser justificada por critérios técnicos claros e, idealmente, acompanhada por análises com e sem essa amostra.

9. Visualizações

Volcano plot

O volcano plot mostra a relação entre o log2 fold-change e a significância estatística ajustada. Genes com valores de padj menores que 0,05 e alteração absoluta de expressão maior que 2 vezes foram destacados.

Heatmap

O heatmap dos principais genes diferencialmente expressos apresentou separação entre as amostras WT e MEIS1 KD. O agrupamento também refletiu a distância relativa da amostra SRR37459108 dentro do grupo MEIS1 KD.

10. GSEA

Foi realizada análise GSEA (*Gene Set Enrichment Analysis*) pré-rankeada utilizando todos os genes disponíveis, ordenados pela estatística do teste de Wald. Os conjuntos de genes foram obtidos da coleção **MSigDB Hallmark 2020** por meio do GSEApY.

Foram utilizados:

- Mínimo de 10 genes por conjunto.
- Máximo de 500 genes por conjunto.
- 1.000 permutações.
- Semente aleatória 42.
- FDR de referência igual a 0,25.

Principais conjuntos suprimidos em MEIS1 KD

Conjunto	NES
G2-M Checkpoint	-2,62
E2F Targets	-2,55
Epithelial Mesenchymal Transition	-2,40
Mitotic Spindle	-2,34
Angiogenesis	-2,33

O conjunto mais ativado foi:

Conjunto	NES
p53 Pathway	+2,32

Interpretação biológica

Os conjuntos mais suprimidos estão relacionados principalmente à proliferação e ao ciclo celular, incluindo checkpoint G2/M, alvos de E2F e fuso mitótico. A ativação relativa da via de p53 é compatível com uma resposta de redução do ciclo celular.

De forma exploratória, os resultados sugerem que o knockdown de **MEIS1** está associado à menor proliferação das células analisadas. Essa interpretação deve ser confirmada com validações adicionais, como replicação biológica independente, análise de marcadores de ciclo celular e confirmação experimental da eficiência do knockdown.

Limitações

- Os dados foram subamostrados por limitação de memória RAM.
- O número efetivo de reads é menor que o disponível no experimento original.
- A amostra SRR37459108 apresenta indícios de qualidade inferior e pode influenciar a análise.
- O índice GRCh38 e o GTF são de fontes/versões que devem ser mantidas consistentes em análises futuras.
- A escolha de `-s 2` no featureCounts deve ser confirmada com a documentação do experimento original.
- A análise diferencial possui apenas três réplicas por condição.
- Os resultados de GSEA indicam associação, não prova causalidade biológica.

Conclusão

Foi construído um pipeline de RNA-seq para comparar células MEIS1 KD e WT. O fluxo incluiu controle de qualidade, alinhamento, quantificação gênica, expressão diferencial, PCA, volcano plot, heatmap e GSEA.

Os principais resultados indicam separação entre as condições experimentais e redução de assinaturas associadas à proliferação e ao ciclo celular no grupo MEIS1 KD. A amostra SRR37459108 apresentou comportamento discrepante em várias etapas, devendo ser investigada com atenção antes de conclusões definitivas.