

Do GEO ao GSEA: Passo a passo da análise de RNA-seq

MEIS1 knockdown × wild type

6 amostras · 3 réplicas por condição

Qualidade → alinhamento → contagem → expressão diferencial → GSEA

Grupo 4: Gabriela Rodrigues; Henrique Macedo; Paulo Henrique Schreiner

Bio12023 - bioinformática geral - turma u (2026/2)

01 • Escolha do conjunto de dados

Busca no GEO Datasets

Series GSE322827		Query DataSets for GSE322827
Status	Public on Sep 13, 2026	
Title	Human-biased MEIS1 expression by a promoter non-coding RNA regulates neural stem cell proliferation	
Organism	Homo sapiens	
Experiment type	Expression profiling by high throughput sequencing	
Summary	MEIS1 promotes NSC proliferation, a process which occurs specifically during human cortical development. To investigate the molecular mechanisms underlying this regulation, we performed RNA-seq to examine the transcriptome changes after MEIS1 knockdown in human NSCs.	
Overall design	Comparative gene expression profiling analysis of RNA-seq data for AF22 NSCs and MEIS1 KD derivative.	
Contributor(s)	Uchida H , Kameda T , Zenno S , Nakashima H , Minato Y , Aritsuka Y , Nishida S , An B , Honda M , Morishita F , Nakashima K , Imamura T	
Citation missing	Has this study been published? Please login to update or notify GEO .	
Submission date	Mar 04, 2026	
Last update date	Sep 14, 2026	
Contact name	Hayato Uchida	
Organization name	Hiroshima University	
Street address	Kagamiyama 1-3-1	
City	Higashi-Hiroshima	
State/province	Hiroshima	
ZIP/Postal code	7398526	
Country	Japan	

([Homo sapiens](#)[Organism]) AND
Expression profiling by high
throughput sequencing AND
stem cell AND 6:8[Number of Samples]

01 • Escolha do conjunto de dados



National Library of Medicine
National Center for Biotechnology Information

Sequence Read Archive

Study > SRP680865

SRP680865

×

Search

Download data in XML format

[? What can be entered in this field?](#)

Human-biased MEIS1 expression by a promoter non-coding RNA regulates neural stem cell proliferation

Identifiers	SRA: SRP680865 BioProject: PRJNA1431924 GEO: GSE322827
Study Type	Transcriptome Analysis
Abstract	MEIS1 promotes NSC proliferation, a process which occurs specifically during human cortical development. To investigate the molecular mechanisms underlying this regulation, we performed RNA-seq to examine the transcriptome changes after MEIS1 knockdown in human NSCs.

Related SRA data

6 EXPERIMENTS

6 SAMPLES

6 RUNS (37.8GB; 25.9GB)

Additional objects

File type	count
fastq	12
SRA Lite	6

Escolhido: GSE322827 / SRP680865. O primeiro candidato não tinha 3 réplicas por condição; este atendia ao desenho.

	Run	BioSample	AvgSpotLen	Bases	Bytes	Experiment	genotype	Library Name	create_date	Sample Name
1	SRR37459106	SAMN56331316	300	6.45 G	4.47 Gb	SRX32366141	MEIS1 knockdown	GSM9560108	2026-03-04 09:22:00Z	GSM9560108
2	SRR37459107	SAMN56331317	300	7.12 G	4.92 Gb	SRX32366140	MEIS1 knockdown	GSM9560107	2026-03-04 09:24:00Z	GSM9560107
3	SRR37459108	SAMN56331318	320	7.05 G	4.71 Gb	SRX32366139	MEIS1 knockdown	GSM9560106	2026-03-04 09:24:00Z	GSM9560106
4	SRR37459109	SAMN56331319	300	3.60 G	2.47 Gb	SRX32366138	WT	GSM9560105	2026-03-04 09:20:00Z	GSM9560105
5	SRR37459110	SAMN56331320	300	6.30 G	4.34 Gb	SRX32366137	WT	GSM9560104	2026-03-04 09:23:00Z	GSM9560104
6	SRR37459111	SAMN56331321	300	7.24 G	5.00 Gb	SRX32366136	WT	GSM9560103	2026-03-04 09:30:00Z	GSM9560103

02 · Ferramentas utilizadas

Aquisição e processamento

- Conda/Mamba · SRA Toolkit
- FastQC · MultiQC
- Seqtk · HISAT2
- SAMtools · featureCounts

Estatística e visualização

- Python · Pandas · NumPy
- PyDESeq2 · MyGene
- Matplotlib · Seaborn
- GSEAPy · MSigDB Hallmark

03 • Download e subamostragem

```
conda create -n sra -c conda-forge -c bioconda "sra-tools>=3.1"  
conda activate sra  
prefetch SRP680865  
fastq-dump SRR37459106 --split-files -O subamostras -X 5000000
```

Repetir para SRR37459107–SRR37459111. Os FASTQ _1 e _2 são as duas extremidades do sequenciamento paired-end.

04 • Controle de qualidade

```
mkdir -p qc_raw
```

```
fastqc -t 4 -o qc_raw ./subamostras/*.fastq.gz
```

```
multiqc qc_raw -o qc_raw
```

05 • Índice de referência GRCh38

```
mkdir -p hisat2_grch38 && cd hisat2_grch38  
wget https://genome-index.s3.amazonaws.com/hisat/grch38_genome.tar.gz  
tar -xzf grch38_genome.tar.gz  
cd ..
```

O índice do HISAT2 contém genome.1.ht2 até genome.8.ht2. Prefixo usado:
./hisat2_grch38/grch38/genome

06 • Alinhamento e BAM

```
hisat2 -p 8 -x ./hisat2_grch38/grch38/genome \  
-1 subamostras/SRR37459106_1.fastq.gz \  
-2 subamostras/SRR37459106_2.fastq.gz \  
| samtools sort -@ 8 -o aligned/SRR37459106.sorted.bam  
samtools index aligned/SRR37459106.sorted.bam  
samtools flagstat aligned/SRR37459106.sorted.bam > aligned/SRR37459106.flagstat.txt
```

Mesmo procedimento para todas as seis amostras.

07 • Erro de memória e ajuste

```
Killed
```

```
(ERR): hisat2-align exited with value 137  
samtools sort: truncated file. Aborting
```

No computador com 8 GB de RAM, o primeiro alinhamento não terminou. A hipótese principal foi esgotamento de memória.

```
seqtk sample -s 100 subamostras/SRR37459106_1.fastq.gz 2500000 \  
| gzip > subamostras_5M/SRR37459106_1.fastq.gz
```

08 • Subamostragem pareada

Aplicou-se seqtk sample com a mesma semente (-s 100) e 2,5 milhões de registros em _1 e _2 de cada amostra.

Resultado: 2,5 milhões de pares por amostra; novo alinhamento foi concluído abaixo do limite de RAM.

09 • Resultado do alinhamento

Amostra	Condição	Taxa geral
SRR37459106	MEIS1 KD	82,77%
SRR37459107	MEIS1 KD	83,78%
SRR37459108	MEIS1 KD	74,81% ← menor
SRR37459109	WT	84,21%
SRR37459110	WT	81,40%
SRR37459111	WT	85,05%

Interpretação: a amostra 08 requer investigação; a taxa sozinha não estabelece a causa.

10 • Contagem gênica

```
featureCounts -T 4 -p -s 2 \  
-a referencia/Homo_sapiens.GRCh38.84.gtf \  
-o counts/all_samples_counts.txt aligned/*.sorted.bam
```

Reads atribuídos: 3.635.388 · 3.615.660 · 3.293.791 · 3.703.521 · 3.559.279 · 3.769.454 (ordem SRR106–111).

10.1 • Contagem gênica

Status	SRR37459106	SRR37459107	SRR37459108	SRR37459109	SRR37459110	SRR37459111
Assigned	3.635.388	3.615.660	3.293.791	3.703.521	3.559.279	3.769.454
Unassigned_Unmapped	861.476	810.810	1.259.647	789.314	930.156	747.419
Unassigned_Read_Type	0	0	0	0	0	0
Unassigned_Singleton	0	0	0	0	0	0
Unassigned_MappingQuality	0	0	0	0	0	0
Unassigned_Chimera	0	0	0	0	0	0
Unassigned_FragmentLength	0	0	0	0	0	0
Unassigned_Duplicate	0	0	0	0	0	0
Unassigned_MultiMapping	537.493	692.789	410.455	600.063	583.868	476.167
Unassigned_Secondary	0	0	0	0	0	0
Unassigned_NonSplit	0	0	0	0	0	0
Unassigned_NoFeatures	210.392	248.498	195.972	205.374	220.738	205.453
Unassigned_Overlapping_Length	0	0	0	0	0	0
Unassigned_Ambiguity	131.211	130.225	125.227	128.588	121.868	129.565

11 • Matriz e metadados

```
counts_raw = pd.read_csv("counts/all_samples_counts.txt", sep="\t", skiprows=1)
# SRR106, 107, 108 → MEIS1_KD; SRR109, 110, 111 → WT
keep = counts.sum(axis=1) >= 10
counts_f = counts.loc[keep]
```


Entrada: 60.675 genes anotados no GTF. Após filtro de soma de contagens ≥ 10 nas seis amostras: 15.631 genes.

12 • Expressão diferencial

```
dds = DeseqDataSet(counts=counts_f.T, metadata=metadata,  
                    design=~condition", refit_cooks=True)  
  
dds.deseq2()  
stat_res = DeseqStats(dds, contrast=["condition", "MEIS1_KD", "WT"])  
stat_res.summary()
```

Critério: $p_{adj} < 0,05$ e $|\log_2\text{FoldChange}| > 1$. Log2FC positivo = maior expressão no MEIS1 KD.

13 • PCA das amostras




PC1 explica 41,8% da variação e separa MEIS1 KD de WT.

SRR37459108 afasta-se das demais réplicas KD, em linha com as métricas de QC e alinhamento.

Pergunta respondida: as condições se separam? Sim, neste conjunto.

14 • Volcano plot




Eixo X: $\log_2\text{FC}$ (KD vs WT).

Eixo Y: $-\log_{10}(\text{padj})$.

Cortes: $\text{padj} < 0,05$ e $|\log_2\text{FC}| > 1$.

A figura destaca genes mais significativos e os mais alterados; não se deve inferir causalidade apenas pelo gráfico.

15 • Heatmap



Top 30 genes por padj; valores VST convertidos em z-score por gene.

As amostras agrupam por condição; o padrão reforça a diferença entre KD e WT.


Uma amostra discrepante dentro do grupo KD ainda merece investigação.

16 • GSEA pré-ranqueado

```
ranking = rank_df.set_index("symbol")["stat"]  
  
pre_res = gp.prerank(rnk=ranking,  
                    gene_sets="MSigDB_Hallmark_2020",  
                    min_size=10, max_size=500,  
                    permutation_num=1000, seed=42)
```

15.631 genes após filtro; 14.804 genes com símbolos na lista GSEA. Ranqueamento pela estatística de Wald; genes Ensembl mapeados para símbolos com MyGene.

17 • Resultados do GSEA




NES negativos no KD:

G2-M -2,62; E2F -2,55; EMT -2,40;
Mitotic Spindle -2,34; Angiogenesis
-2,33.

NES positivo: p53 Pathway +2,32.

FDR descrito como ≈ 0 no arquivo;
consultar CSV para valores exatos.

18 • Curvas de enriquecimento



Running score dos três conjuntos mais suprimidos:

G2-M Checkpoint

E2F Targets

Epithelial Mesenchymal Transition

NES negativo =
enriquecimento do lado de
genes reduzidos no KD.

19 • Perguntas respondidas

1. O dataset tinha replicação? Sim: 3 MEIS1 KD + 3 WT.
2. Houve problema técnico? Sim: erro 137 por provável falta de RAM; corrigido com subamostragem.
3. Alguma amostra destoou? Sim: SRR37459108 em QC, alinhamento, contagem e PCA.
4. KD e WT se separam? Sim, na PCA e no heatmap.
5. Quais vias aparecem alteradas? Ciclo celular/proliferação com NES negativo; p53 com NES positivo.